مقدمة المشروع

يهدف هذا المشروع إلى تطبيق مفاهيم تحليل البيانات واستخراج المعرفة من البيانات (Data Analytics) على بيانات حقيقية خاصة ببطولة كأس العالم لكرة القدم (FIFA World Cup)، والتي تعد من أكبر الأحداث الرياضية العالمية وأكثرها غنى بالبيانات والإحصائيات التاريخية.

من خلال هذا المشروع سيكتسب الطلاب خبرة عملية في دورة حياة تحليل البيانات كاملة، بدءاً من فهم البيانات ومعالجتها، مروراً بالتحليل الاستكشافي واستخراج الأنماط والمؤشرات المهمة، وانتهاء ببناء تصورات بصرية ولوحات معلومات تفاعلية تروي قصة البيانات وتساعد على اتخاذ القرارات وفهم الظواهر الرياضية عبر الزمن.

هدف المشروع:

تخيل أنك انضممت حديثاً كـ **Data Analyst** إلى شركة استشارات رياضية تتعاون مع:

- شبكة بث رياضي عالمية تحضّر تغطيتها لكأس العالم 2026
- جهات تسويق ورعاية (sponsorship) تريد تحديد الأسواق والفئات الأكثر جاذبية
- فرق تخطيط تشغيلي تريد فهم أنماط الحضور (attendance) والمباريات لتوزيع الموارد.

مهمتك: تحليل تاريخ كأس العالم من 1930 إلى 2022، واستخدام هذا التحليل لبناء توصيات وتوقعات حول نسخة 2026، ثم تقديم كل ذلك في تقرير قابل للفهم لجهة غير تقنية(Executive Report)

نبذة عن البيانات

يعتمد المشروع على مجموعة بيانات شاملة خاصة ببطولات كأس العالمFIFA World Cup ، وتغطي الفترة الممتدة من عام 1930 وحتى بطولة 2026. تتكون البيانات من خمسة ملفات مترابطة توفر معلومات تاريخية وتفصيلية عن البطولات والمنتخبات والمباريات والهدافين.

wc_all_editions.csv

يحتوي على ملخص لجميع نسخ كأس العالم من عام 1930 حتى عام 2022، ويتضمن معلومات عامة عن كل بطولة مثل الدولة المستضيفة، البطل، الوصيف، الهداف، عدد الأهداف المسجلة، الحضور الجماهيري، ونظام البطولة.

wc_all_matches.csv

يحتوي على بيانات المباريات عبر جميع نسخ كأس العالم، بما في ذلك المنتخبات المتنافسة، النتائج النهائية، المرحلة التي أقيمت فيها المباراة، الملعب، المدينة، الدولة، وتاريخ المباراة.

wc_top_scorers.csv

يتضمن بيانات هداف البطولة (Golden Boot Winner) لكل نسخة من كأس العالم، مع معلومات عن اللاعب وجنسيته ومركزه وعدد أهدافه وتمريراته الحاسمة وعدد المباريات التي لعبها ونتيجة منتخب بلاده في البطولة.

wc_2026_teams.csv

يوفر معلومات عن المنتخبات الـ 48 المتأهلة إلى كأس العالم 2026، بما في ذلك المجموعة، القارة، تصنيف FIFA، المدرب، أفضل إنجاز سابق في كأس العالم، وما إذا كانت المشاركة الأولى للمنتخب في البطولة.

wc_2026_fixtures.csv

يتضمن جدول مباريات كأس العالم 2026 كاملاً، مع معلومات عن الفرق المتقابلة، المجموعة أو المرحلة، الملعب، المدينة، الدولة المستضيفة، موعد المباراة، تصنيف FIFA للمنتخبين، القارة التي ينتمي إليها كل منتخب، وأسماء المدربين.

تتيح هذه البيانات إجراء تحليلات تاريخية ومقارنات زمنية ودراسات أداء للمنتخبات واللاعبين، بالإضافة إلى بناء لوحات معلومات تفاعلية وقصص بيانية تستكشف تطور البطولة على مدى ما يقارب قرناً من الزمن.

قيود وقواعد تنظيمية

- يتم العمل على المشروع بشكل فريق مكون من 3 مهندسين كحد أقصى.
- يسلم المشروع بشكل ملف يحوي الأكواد المصدرية بالإضافة إلى ملف pdf يحوي ملاحظاتكم، وأهم النتائج المستخلصة والتحديات التي واجهتكم.
- خصصوا وقتاً كافياً لإكمال التحدي دون تسرّع، ابدؤوا مبكراً وخططوا للحصول على البيانات، المعالجة، والتحليل قبل اللحظة الأخيرة.
- **اسألوا المدرّب عند وجود أي استفسار حول التحدي.**
- **ابتعدوا عن أدوات الذكاء الصناعي في توليد الحل، وحاولوا أن تواجهوا التحديات وتحلوها بأنفسكم بدلاً من الاعتماد عليه.**
- لا تتركوا أي رسالة خطأ (error) أو طباعة مخرجات طويلة جداً ضمن المفكرة النهائية
- الاستنتاجات يمكن كتابتها بالعربية أو الإنجليزية أو مزيج منهما (وضّحوا المصطلحات الإنجليزية بين قوسين إن استخدمت ضمن نص عربي).

المرحلة 0: الاستكشاف الأولي(Initial Exploration)

1- حمّل الخمسة ملفات في DataFrames منفصلة. لكل ملف اعرض:

.()info,.shape, .columns, .dtypes, .head()

2- كل ملف، حدد:

الأعمدة التي تتوقع أنها ستكون مفتاح ربط (join key) مع ملفات أخرى (مثل اسم الدولة، السنة، الفريق)

أي أعمدة تبدو غير ضرورية لتحليلنا (business-irrelevant) ولماذا؟

المرحلة 1: تنظيف البيانات(Data Cleaning)

1- Missing Values:

لكل عمود فيه قيم مفقودة، اقترح استراتيجية تعامل (drop / fill / flag) مع تبرير منطقي يأخذ السياق بعين الاعتبار)

مثلاً: عمود "assists" مفقود في نسخ قديمة قد يعني أن البيانات لم تكن تُسجل أصلاً، وليس أن القيمة = صفر

2- Duplicates:

تحقق من وجود صفوف متكررة في أي من الملفات المتعلقة بهذه البيانات وحدد نوع هذا التكرار.

3- Score Parsing

إن كانت نتيجة المباراة مخزّنة كنص (1-3 مثلاً) قسمها إلى عمودين
رقميين home_goalsوaway_goals، وتحقق من النوع (dtype) بعد التحويل.

4- Naming Consistency

استخرج كل أسماء الدول/الفرق الفريدة من wc_all_matches.csvوwc_all_editions.csv،
وافحص إن وجدت أسماء قد تشير لنفس الدولة بمسميات مختلفة عبر العصور

مثال نمطي يجب التحقق منه فعلياً في بياناتك وليس افتراضه "West Germany" :مقابل
"Germany"، أو دول لم تعد موجودة سياسياً .(إن وجدت حالات، وثقها ووحدها بطريقة مناسبة.

5- Date/Year Types

تأكد أن أعمدة السنة/التاريخ من نوع رقمي أو datetime وليست نصاً.

المرحلة 2: تحليل البيانات

القسم الأول: المؤشرات العامة للبطولة

1. كم عدد نسخ كأس العالم الموجودة في البيانات؟
2. كم عدد المباريات الإجمالي؟
3. كم عدد الأهداف المسجلة عبر تاريخ البطولة؟
4. ما متوسط عدد الأهداف في المباراة الواحدة؟
5. ما متوسط الحضور الجماهيري لكل بطولة؟
6. ما عدد الدول التي استضافت البطولة؟
7. ما عدد المنتخبات المختلفة التي شاركت في كأس العالم؟

القسم الثاني: تطور البطولة عبر الزمن

1. كيف تغير عدد الأهداف عبر نسخ البطولة؟
2. كيف تغير الحضور الجماهيري عبر الزمن؟
3. كيف تغير متوسط الأهداف في المباراة الواحدة؟
4. كيف تطور عدد المنتخبات المشاركة؟
5. ما البطولات التي تعتبر شاذة (Outliers) من حيث الأهداف أو الحضور؟ هل هي خطأ في البيانات أم حدث حقيقي استثنائي؟
6. هل توجد فترات زمنية يمكن اعتبارها الأكثر هجومية في تاريخ كأس العالم؟

القسم الثالث: تحليل المنتخبات

1. ما أكثر المنتخبات تتويجاً بالبطولة؟
2. ما أكثر المنتخبات وصولاً للنهائي؟
3. ما أكثر المنتخبات ظهوراً في البطولة؟
4. ما أكثر المنتخبات تسجيلاً للأهداف؟
5. ما أكثر المنتخبات استقبالاً للأهداف؟
6. ما المنتخبات ذات أفضل معدل فوز؟

القسم الرابع: تحليل المباريات

1. هل مباريات الأدوار الإقصائية أقل تهديفاً من دور المجموعات؟
2. ما المراحل التي تشهد أكبر عدد من الأهداف؟
3. كيف يتوزع عدد الأهداف على المباريات؟

القسم الخامس: تحليل الأبطال والنجاح الرياضي

1. رتب المنتخبات وفق عدد مرات :
   - الفوز بالبطولة .
   - الوصول إلى النهائي .
   - إنهاء البطولة ضمن المراكز الثلاثة الأولى .
2. هل يوجد عدد محدود من المنتخبات يهيمن على تاريخ البطولة؟
3. كيف تغيرت هيمنة المنتخبات الكبرى عبر العقود المختلفة؟

القسم السادس: تحليل الهدافين

1. كيف تغير عدد أهداف هداف البطولة عبر الزمن؟
2. ما الدول الأكثر إنتاجاً لهدافي البطولة؟
3. هل ينتمي هداف البطولة غالباً إلى منتخب ناجح؟
4. هل يوجد ارتباط بين عدد المباريات التي لعبها الهداف وعدد أهدافه؟

القسم السابع: كأس العالم 2026

1. كيف تتوزع المنتخبات المتأهلة على القارات؟
2. ما القارة صاحبة أعلى متوسط تصنيفFIFA ؟
3. ما المجموعة الأقوى؟
4. ما المجموعة الأكثر توازناً؟
5. ما المباريات المتوقع أن تكون الأكثر تنافسية اعتماداً على تصنيفFIFA ؟
6. كيف تتوزع المباريات بين المدن والدول المستضيفة؟

القسم الثامن: أسئلة تحليلية متقدمة

1. هل يمنح عامل الأرض أفضلية حقيقية للدولة المستضيفة؟
2. هل توجد علاقة بين الحضور الجماهيري وعدد الأهداف؟
3. هل أصبحت البطولة أكثر تنافسية مع مرور الزمن؟
4. هل تأتي ألقاب كأس العالم من مجموعة صغيرة من الدول أم أن المنافسة أصبحت أكثر تنوعاً؟

القسم التاسعStorytelling :

Executive Dashboard:

اختر 4-6 من أقوى الرسوم البيانية التي بنيتها، وجمّعها في لوحة واحدة موجهة لمسؤول تنفيذي غير تقني.

Executive Summary:

اكتب صفحة واحدة تحتوي على 3 نتائج رئيسية(key findings) ، كل نتيجة مدعومة برسم بياني واحد + 2-3 جمل تفسير بلغة بسيطة + توصية عملية واحدة قابلة للتنفيذ (مثال: "بناءً على ارتفاع الحضور في [منطقة] خلال [حقبة]، نوصي بـ...").